

Clasificación de Lesiones Cutáneas Pigmentadas mediante Redes Neuronales Convolucionales (HAM10000)

Estudiante: Diego Alejandro Rendón Suaza C.C. 1.007.347.028

Ingeniería de Sistemas — Universidad de Antioquia

Profesores: Raúl Ramos | Julián Arias

Proyecto Final — Entrega 1 | Módulo 4: Convolutional Networks | Fundamentos de Deep Learning

Marzo 2026

1. Contexto de Aplicación

El cáncer de piel es una de las enfermedades oncológicas más prevalentes a nivel mundial. Su detección temprana es crítica: en estadios iniciales la tasa de supervivencia a cinco años supera el 98 %, mientras que en estadios avanzados puede caer por debajo del 20 % [2]. El diagnóstico clínico se apoya en la *dermatoscopia*, técnica de imagen no invasiva que revela estructuras cutáneas invisibles a simple vista, pero cuya interpretación requiere formación especializada y es propensa a variabilidad inter-observador.

Las Redes Neuronales Convolucionales (CNNs) han demostrado un rendimiento equivalente al de dermatólogos certificados en la clasificación de imágenes dermatoscópicas [2]. Este proyecto busca no solo construir un clasificador preciso sobre el dataset **HAM10000**, sino **comparar sistemáticamente distintas arquitecturas y técnicas CNN**, evaluando cómo cada decisión de diseño impacta el rendimiento en un problema médico real con desbalance severo de clases.

2. Objetivo de Machine Learning

El objetivo central es **comparar el desempeño de distintas arquitecturas CNN** aplicadas a la clasificación de lesiones cutáneas, siguiendo un plan de iteraciones con complejidad creciente:

Iteración 1 — CNN desde cero (línea de base): Clasificación **binaria** (maligno vs. benigno) con una CNN propia entrenada desde cero en PyTorch, con capas convolucionales, *max pooling* y *dropout*. Permite validar el pipeline completo y establecer una línea de base.

Iteración 2 — Transfer learning con arquitecturas preentrenadas: Comparación de tres arquitecturas sobre la misma tarea binaria, usando modelos preentrenados en ImageNet con *fine-tuning*:

- **VGG16** [4] — red profunda con filtros uniformes 3×3 .
- **ResNet50** [3] — aprendizaje residual con conexiones de salto (*skip connections*).
- **EfficientNet-B0** [5] — escalado compuesto de profundidad, anchura y resolución.

Iteración 3 — Clasificación multiclase (7 clases): Extender la mejor arquitectura de la iteración anterior a las **7 categorías diagnósticas** completas del dataset, con manejo explícito del desbalance y análisis por clase.

Especificación formal:

- **Entrada (X):** Imagen dermatoscópica RGB, 600×450 px, redimensionada a 224×224 px.
- **Salida ($\hat{y}$):** Etiqueta binaria {maligno, benigno} (it. 1–2) o una de 7 clases (it. 3).
- **Framework:** PyTorch con torchvision.models para arquitecturas preentrenadas.
- **Desbalance:** WeightedRandomSampler y CrossEntropyLoss con pesos por clase.
- **Regularización:** Data augmentation (rotaciones, flips, variaciones de brillo/color) y Dropout.

3. Dataset

Se utilizará el **HAM10000** (*Human Against Machine with 10000 training images*), publicado por Tschandl et al. [1] y empleado como benchmark oficial en la competición ISIC 2018 Task 3. Es el dataset de referencia estándar para clasificación de lesiones cutáneas en aprendizaje profundo médico.

Acceso a los datos: El dataset se descargará localmente mediante la API de Kaggle (`kaggle datasets download kmader/skin-cancer-mnist-ham10000`) y se organizará en carpetas por clase para su carga con `torchvision.datasets.ImageFolder`.

Característica	Detalle
Total de imágenes	10,015 imágenes dermatoscópicas
Resolución	600×450 px, formato JPG
Tamaño en disco	≈ 2.58 GB
Número de clases	7 diagnósticos (multiclase) / 2 agrupadas (binario)
Metadatos	Edad, sexo, localización corporal, método diagnóstico
Validación	>50 % histopatología; resto por consenso experto o microscopía confocal
Licencia	CC BY-NC 4.0
Fuente	Kaggle / Harvard Dataverse

Distribución de clases y agrupación para clasificación binaria:

Código	Diagnóstico	Imágenes	%	Grupo binario
nv	Melanocytic nevi	6,705	66.9 %	Benigno
mel	Melanoma	1,113	11.1 %	Maligno
bkl	Benign keratosis-like lesions	1,099	11.0 %	Benigno
bcc	Basal cell carcinoma	514	5.1 %	Maligno
akiec	Actinic keratoses / Bowen's	327	3.3 %	Maligno
vasc	Vascular lesions	142	1.4 %	Benigno
df	Dermatofibroma	115	1.1 %	Benigno
Total		10,015	100 %	
Grupo maligno (mel + bcc + akiec)		1,954	19.5 %	
Grupo benigno (nv + bkl + vasc + df)		8,061	80.5 %	

El desbalance binario es de $\sim 4:1$. En la tarea multiclase se agudiza: nv representa el 66.9 % mientras df y vasc suman apenas el 2.5 %. Ambos escenarios requieren estrategias explícitas de

manejo de desbalance.

Requerimientos computacionales: El entrenamiento se realizará en máquina local. Se estima que cada época de entrenamiento toma entre 3–8 minutos dependiendo de la arquitectura (CPU vs. GPU). Para las iteraciones con *transfer learning*, se recomienda un mínimo de 8 GB de RAM y, de estar disponible, una GPU con al menos 4 GB de VRAM para reducir los tiempos de entrenamiento a $\sim 1\text{--}2$ min/época. El dataset completo (2.58 GB) se cargará en disco y se procesará en lotes (*batch size* de 32) para evitar saturar la memoria.

4. Métricas de Desempeño

Dado el desbalance severo, la exactitud (*accuracy*) global no es representativa: un modelo trivial que prediga siempre *nv* obtendría 66.9 % sin aprender nada útil. Se emplearán métricas robustas que permitan además **comparar las distintas arquitecturas** entre sí:

Métricas de machine learning:

- **Balanced Accuracy:** Métrica principal de comparación; promedio del recall por clase, robusta ante el desbalance.
- **AUC-ROC macro:** Capacidad discriminativa independiente del umbral de decisión.
- **F1-Score macro:** Media armónica de precisión y recall. *Línea de base de referencia: $F1 = 0.73$ con CNN desde cero en TensorFlow [?].*
- **Matriz de confusión:** Análisis cualitativo de los errores entre pares de clases por modelo.
- **Curvas de entrenamiento** (pérdida y métricas por época): Para detectar sobreajuste y comparar convergencia entre arquitecturas.

Métricas de impacto clínico:

- **Recall para clases malignas** (*mel*, *bcc*, *akiec*): Un falso negativo implica no detectar un cáncer real. Objetivo: Recall > 85 % para melanoma.
- **Tasa de falsos negativos (FNR):** Captura el riesgo clínico directo de omitir un diagnóstico maligno.

5. Referencias y Resultados Previos

Referencias

- [1] Tschandl, P., Rosendahl, C., & Kittler, H. (2018). *The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions*. Scientific Data, 5, 180161. doi:10.1038/sdata.2018.161
- [2] Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., & Thrun, S. (2017). *Dermatologist-level classification of skin cancer with deep neural networks*. Nature, 542, 115–118. doi:10.1038/nature21056
- [3] He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep Residual Learning for Image Recognition*. CVPR 2016. doi:10.1109/CVPR.2016.90
- [4] Simonyan, K., & Zisserman, A. (2014). *Very Deep Convolutional Networks for Large-Scale Image Recognition*. arXiv:1409.1556. arxiv:1409.1556
- [5] Tan, M., & Le, Q. V. (2019). *EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks*. ICML 2019. arxiv:1905.11946