

INFORME FINAL DE PROYECTO

Clasificación de Lesiones Cutáneas Pigmentadas mediante Redes Neuronales Convolucionales (HAM10000)

Estudiante: Diego Alejandro Rendon Suaza C.C.
1.007.347.028

Ingeniería de Sistemas — Universidad de Antioquia

Profesores: Raul Ramos | Julian Arias

Modulo 4: Convolutional Networks | Fundamentos de Deep Learning Junio
2026

1. Introduccion y Contexto

El cancer de piel es una de las enfermedades oncologicas mas prevalentes a nivel mundial. Su deteccion temprana es critica: en estadios iniciales la tasa de supervivencia a cinco anos supera el 98%, mientras que en estadios avanzados puede caer por debajo del 20% [2]. El diagnostico clinico se apoya en la dermatoscopia, tecnica de imagen no invasiva que revela estructuras cutaneas invisibles a simple vista, pero cuya interpretacion requiere formacion especializada y es propensa a variabilidad inter-observador.

Las Redes Neuronales Convolucionales (CNNs) han demostrado un rendimiento equivalente al de dermatologos certificados en la clasificacion de imagenes dermatoscopicas [2]. Este proyecto aborda la clasificacion automatica de lesiones cutaneas pigmentadas sobre el dataset HAM10000, comparando sistematicamente distintas arquitecturas CNN y evaluando el impacto de las estrategias de mitigacion del desbalance de clases.

El proyecto sigue un plan de tres iteraciones con complejidad creciente: una CNN entrenada desde cero como linea de base, transfer learning con tres arquitecturas preentrenadas en tarea binaria, y finalmente clasificacion multiclase de las siete categorias diagnosticas.

2. Objetivos del Proyecto

Objetivo general:

Comparar el desempeno de distintas arquitecturas CNN aplicadas a la clasificacion de lesiones cutaneas pigmentadas, evaluando el efecto de las estrategias de mitigacion del desbalance de clases sobre las metricas clinicamente relevantes.

Objetivos especificos:

- Establecer una linea de base con una CNN propia y demostrar cuantitativamente el efecto de los pesos de clase sobre el recall de lesiones malignas.
- Comparar VGG16, ResNet50 y EfficientNet-B0 con feature extraction en clasificacion binaria, evaluando en test set con metricas robustas al desbalance.

- Extender la mejor arquitectura a clasificacion multiclase de 7 categorias con finetuning progresivo y analisis de rendimiento por clase.
- Garantizar reproducibilidad completa mediante split por paciente (GroupShuffleSplit sobre lesion_id), semilla fija SEED=42 y descarga automatica de datos.

3. Dataset Utilizado

Se utilizo el **HAM10000** (Human Against Machine with 10000 training images), publicado por Tschandl et al. [1] y empleado como benchmark oficial en la competicion ISIC 2018 Task 3. Es el dataset de referencia estandar para clasificacion de lesiones cutaneas en aprendizaje profundo medico.

Caracteristica	Detalle
Total de imagenes	10,015 imagenes dermatoscopicas
Formato	JPG, color RGB (3 canales confirmados experimentalmente)
Resolucion original	600 x 450 px — rango de valores: [43, 255] uint8
Resolucion de entrada	224 x 224 px (redimensionado para modelos preentrenados)
Tamano en disco	aprox. 2.58 GB
Numero de clases	7 diagnosticos (multiclase) / 2 agrupadas (binario)
Metadatos	Edad, sexo, localizacion corporal, metodo diagnostico
Validacion diagnostica	>50% histopatologia; resto consenso experto o microscopia confocal
Licencia	CC BY-NC 4.0 — Kaggle / Harvard Dataverse

Distribucion de clases:

Codigo	Diagnostico	Imagenes	%	Grupo Binario
nv	Melanocytic nevi	6,705	66.9%	Benigno
mel	Melanoma	1,113	11.1%	Maligno
bkl	Benign keratosis-like lesions	1,099	11.0%	Benigno
bcc	Basal cell carcinoma	514	5.1%	Maligno
akiec	Actinic keratoses / Bowen's	327	3.3%	Maligno
vasc	Vascular lesions	142	1.4%	Benigno
df	Dermatofibroma	115	1.1%	Benigno
	TOTAL	10,015	100%	




Figura 1. Distribucion de clases y desbalance binario (NB01).

El grupo maligno (*mel + bcc + akiec*) representa el 19.5% del dataset, con un ratio de desbalance binario de 4.1:1. En la tarea multiclase el desbalance se agudiza: *nv* representa el 66.9% mientras *df* y *vasc* suman apenas el 2.5%.

Particion del dataset por paciente:

El split se realizo con **GroupShuffleSplit sobre lesion_id**, garantizando que todas las imagenes de un mismo paciente pertenezcan exclusivamente a un unico subconjunto y previniendo data leakage de paciente.

Subconjunto	Imagenes	% del total	Proposito
Train	7,984	79.7%	Entrenamiento
Val	1,005	10.0%	Seleccion de hiperparametros
Test	1,026	10.2%	Evaluacion final (nunca visto)
TOTAL	10,015	100%	

4. Analisis Exploratorio de Datos

El analisis exploratorio (NB01) revelo las siguientes caracteristicas fundamentales:

Formato de las imagenes: todas las imagenes son dermatoscopicas en color con **3 canales RGB** confirmados experimentalmente (forma del tensor: [32, 3, 224, 224]). La resolucion original es 600x450 px. Tras normalizacion ImageNet el rango del tensor es [-2.118, 2.640].

Desbalance severo: un modelo trivial que prediga siempre 'nv' obtendria 66.9% de accuracy sin aprender nada util, lo que hace que la accuracy simple sea una metrica enganosa para este problema.

Pacientes duplicados: el analisis de lesion_id mostro lesiones con hasta 6 imagenes asociadas. Un split aleatorio generaria data leakage de paciente, inflando artificialmente las metricas de evaluacion.




Figura 2. Efecto del data augmentation sobre imagenes dermatoscópicas (NB01).

5. Preprocesamiento

Transformacion	Train	Val/Test	Justificacion Clinica
Resize(224x224)	Si	Si	Estandar para modelos preentrenados ImageNet
RandomHorizontalFlip	Si	No	Una lesion puede aparecer en cualquier orientacion lateral
RandomVerticalFlip	Si	No	Invarianza vertical clinicamente valida
RandomRotation(90)	Si	No	Invarianza rotacional valida en dermatoscopia
ColorJitter(bright=0.1)	Si	No	de iluminacion — jitter de color OMITIDO porque el color es una variable diagnostica directa
ToTensor + Normalize	Si	Si	Normalizacion ImageNet estandar

Se descarto ColorJitter con parametros de saturacion o matiz porque en dermatoscopia el color es una variable diagnostica directa. Alterar la cromaticidad equivaldria a modificar informacion clinica relevante.

Pesos de clase calculados (train set):

Clase	Imagenes (train)	Peso asignado
nv	5,359	0.213
mel	864	1.320
bkl	885	1.289
bcc	415	2.748
akiec	261	4.370

vasc	109	10.464
df	91	12.534

6. Arquitecturas y Modelos Implementados

6.1 CNN Baseline desde cero — Iteracion 1

CNN propia con 3 bloques convolucionales (Conv2d + BatchNorm + ReLU + MaxPool) seguidos de un clasificador FC con Dropout(0.5). Entrenada durante 10 epocas en dos variantes: sin pesos de clase y con pesos de clase.

Componente	Detalle
Entrada	Tensor RGB 3x224x224
Bloque 1	Conv2d(3->16, 3x3) + BN + ReLU + MaxPool(2x2)
Bloque 2	Conv2d(16->32, 3x3) + BN + ReLU + MaxPool(2x2)
Bloque 3	Conv2d(32->64, 3x3) + BN + ReLU + MaxPool(2x2)
FC	Linear(64*28*28, 256) -> ReLU -> Dropout(0.5) -> Linear(256, 2)
Optimizador	Adam lr=0.001 CrossEntropyLoss (con/sin pesos)

6.2 Transfer Learning — Iteracion 2

Feature extraction con backbone congelado y cabeza de clasificacion de 2 neuronas. Todos los modelos usan CrossEntropyLoss con pesos de clase.

Arquitectura	Descripcion	Ref
VGG16	Red profunda con filtros uniformes 3x3	[4]
ResNet50	Aprendizaje residual con skip connections	[3]
EfficientNet-B0	Escalado compuesto profundidad/anchura/resolucion	[5]

6.3 ResNet50 Multiclase con Fine-tuning Progresivo — Iteracion 3

- **Fase 1 (8 epocas, lr=0.001):** solo se entrena la capa FC (7 clases). Backbone completamente congelado.
- **Fase 2 (5 epocas, lr=0.0001):** se descongela layer4 del backbone con LR 10x menor para especializar representaciones sin destruir pesos ImageNet.

7. Experimentos y Resultados

7.1 Iteracion 1 — Efecto de los Pesos de Clase (CNN Baseline)

Se entrenaron dos variantes identicas de la CNN baseline durante 10 épocas, diferenciadas unicamente por la inclusion o exclusion de pesos en CrossEntropyLoss.

Metrica	Sin pesos	Con pesos	Delta
Accuracy	0.8012	0.7398	-0.061
Balanced Accuracy	0.5000	0.6441	+0.144
F1-Score Macro	0.4448	0.6288	+0.184
AUC-ROC	0.8218	0.7723	-0.049
Recall Maligno	0.00	0.49	+0.490
Precision Maligno	0.00	0.38	+0.380




Figura 3. Curvas de aprendizaje: efecto de los pesos de clase en CNN baseline (NB02).




Figura 4. Matrices de confusion y curvas ROC del modelo baseline (NB02).

El modelo sin pesos predice el 100% de los casos como benignos (recall=0.00 en malignos), obteniendo balanced accuracy de 0.50 — equivalente a un clasificador aleatorio. Con pesos de clase la balanced accuracy sube +14.4 puntos y el recall de malignos alcanza 0.49. El AUC-ROC mas alto del modelo sin pesos (0.822 vs 0.772) se explica porque mide la capacidad discriminativa de las probabilidades brutas, no del umbral de decision: el modelo sin pesos genera probabilidades bien ordenadas pero con umbral sesgado hacia la clase mayoritaria.

7.2 Iteracion 2 — Comparativa de Arquitecturas Preentrenadas

Se compararon VGG16, ResNet50 y EfficientNet-B0 con feature extraction durante 5 epocas, todos con pesos de clase en la funcion de perdida.

Modelo	Accuracy	Balanced Acc	F1 Macro	AUC-ROC	Recall Mal.	Prec. Mal.
VGG16	0.7456	0.7344	0.6770	0.8071	0.72	0.42

ResNet50	0.8099	0.7450	0.7247	0.8503	0.64	0.52
EfficientNet-B0	0.7534	0.7687	0.6950	0.8418	0.79	0.43




Figura 5. Curvas de aprendizaje comparativas — transfer learning binario (NB03).




Figura 6. Evaluación en test set — VGG16, ResNet50 y EfficientNet-B0 (NB03).

ResNet50 lidera en accuracy (0.810), F1-Macro (0.725) y AUC-ROC (0.850), con la menor pérdida de validación (0.356). EfficientNet-B0 logra el mayor recall de malignos (0.79) pero genera 211 falsos positivos frente a 121 de ResNet50. Se seleccionó ResNet50 para la Iteración 3 por su mejor

equilibrio entre todas las metricas y su idoneidad para fine-tuning progresivo basado en bloques residuales.

7.3 Iteracion 3 — Clasificacion Multiclase con Fine-tuning Progresivo

ResNet50 extendido a 7 clases con entrenamiento en dos fases. Las curvas muestran un salto claro en accuracy de validacion al inicio de la Fase 2 (~ 0.64 a ~ 0.75), confirmando el efecto del descongelamiento de layer4.

Metrica	Valor
Accuracy	0.7427
Balanced Accuracy	0.6937
F1-Score Macro	0.6024
AUC-ROC Macro (OvR)	0.9494




Figura 7. Curvas de aprendizaje — fine-tuning progresivo en dos fases (NB04).

Rendimiento por clase (test set):

Clase	Nombre	Precision	Recall	F1	AUC-ROC	Support
nv	Melanocytic nevi	0.94	0.79	0.86	0.941	676
mel	Melanoma	0.47	0.54	0.50	0.891	122
bkl	Benign keratosis	0.53	0.66	0.59	0.926	113
bcc	Basal cell carcinoma	0.48	0.74	0.58	0.961	50
akiec	Actinic keratoses	0.45	0.75	0.56	0.975	32
vasc	Vascular lesions	0.69	0.87	0.77	0.996	23

df	Dermatofibroma	0.26	0.50	0.34	0.954	10
----	----------------	------	------	------	-------	----




Figura 8. Matriz de confusion — ResNet50 multiclase (NB04).




Figura 9. Curvas ROC one-vs-rest por clase — ResNet50 multiclase (NB04).

8. Discusion de Resultados

8.1 Efecto de las estrategias de mitigacion del desbalance

El experimento comparativo del NB02 proporciona evidencia cuantitativa clara. Sin pesos de clase el modelo aprende a predecir siempre 'benigno' con recall cero en malignos — inaceptable clinicamente. Con pesos, la balanced accuracy mejora +14.4 puntos y el recall de malignos sube de

0.00 a 0.49.

El data augmentation clinicamente valido contribuyo a la generalizacion. Se descarto deliberadamente el jitter de color y saturacion dado que el color es una variable diagnostica central en dermatoscopia (criterio ABCD).

8.2 Transfer learning vs. CNN desde cero

La balanced accuracy mejoro de 0.644 (baseline con pesos) a 0.745 (ResNet50 binario), un incremento de +10.1 puntos con solo 5 epocas de entrenamiento. Las representaciones preentrenadas en ImageNet se transfieren efectivamente a imagenes medicas dermatoscopicas.

8.3 Analisis del modelo multiclase

El AUC-ROC macro de 0.9494 es sobresaliente, especialmente considerando el desbalance severo. Indica alta capacidad discriminativa a nivel probabilistico. El fine-tuning progresivo produjo una mejora visible y medible: la accuracy de validacion salto de ~0.64 a ~0.75 exactamente al inicio de la Fase 2.

- **vasc (AUC 0.996, recall 0.87):** mejor rendimiento — patrones cromaticos y texturales muy distintivos facilitaron el aprendizaje.
- **mel (AUC 0.891, recall 0.54):** clase mas critica clinicamente. El 18% de melanomas se confunden con nv, coherente con la literatura: el melanoma temprano puede ser morfologicamente similar a nevos benignos.
- **df (recall 0.50, support=10):** resultado con precaucion estadistica — solo 10 muestras en test. El 40% se confunde con melanoma.

8.4 Metricas de impacto clinico

A diferencia de las metricas de ML, las metricas de impacto clinico evaluan el efecto del despliegue en el sistema de salud real. No son medibles durante el desarrollo del proyecto, pero su discusion es fundamental:

- **Reduccion de variabilidad inter-observador:** un sistema de apoyo a la decision podria estandarizar el triaje inicial, reduciendo dependencia de la experiencia del observador.
- **Tiempo de respuesta:** en atencion primaria o zonas sin dermatologo, una clasificacion automatica en segundos aceleraria la derivacion de casos urgentes.
- **Tasa de biopsias innecesarias:** el modelo podria reducir biopsias en lesiones benignas de alta confianza, pero requiere validacion clinica rigurosa.
- **Falsos negativos en melanoma (recall 0.54):** el modelo actual no es apto para uso clinico autonomo. Su rol apropiado seria como segundo revisor o herramienta de triaje complementaria al juicio del dermatologo.

9. Limitaciones

- **Soportes pequenos:** vasc (23 en test) y df (10 en test) tienen soportes muy pequenos para evaluacion estadisticamente robusta.
- **Entrenamiento en CPU:** limite el numero de epocas y el batch size. Con GPU los modelos podrian alcanzar mejor convergencia.

- **Feature extraction parcial:** en las Iteraciones 1-2 se congelo el backbone completo. Un fine-tuning mas profundo podria mejorar resultados.
- **Sin validacion externa:** la generalizacion a imagenes de otros equipos dermatoscopicos o poblaciones distintas no ha sido evaluada.
- **Recall de melanoma (0.54):** por debajo del objetivo declarado (>85%). Requiere iteraciones adicionales.

10. Trabajo Futuro

- **Full fine-tuning progresivo:** descongelar gradualmente todos los bloques (layer3 -> layer2 -> layer1) con learning rates decrecientes.
- **Ensemble de modelos:** combinar ResNet50 y EfficientNet-B0 para aprovechar la complementariedad (precision vs. sensibilidad).
- **Grad-CAM:** visualizar regiones activadas en la decision del modelo para facilitar la validacion clinica e interpretabilidad.
- **Calibracion de probabilidades:** temperatura scaling para mejorar la calibracion de salidas — critico para uso clinico.
- **Validacion externa:** evaluar en ISIC 2019 / ISIC 2020 para medir generalizacion real a datos de otras fuentes.

11. Estructura del Repositorio y Reproducibilidad

Archivo	Descripcion
01_exploracion_y_preprocesado.ipynb	EDA, RGB, split por lesion_id, pesos de clase
02_arquitectura_linea_base_binaria.ipynb	CNN baseline, comparativa sin/con pesos
03_transfer_learning_binario.ipynb	VGG16, ResNet50, EfficientNet-B0 comparativa
04_clasificacion_multiclase.ipynb	ResNet50 + fine-tuning 2 fases, ROC por clase
INFORME_PROYECTO.PDF	Este informe
ENTREGA1.PDF	Propuesta inicial del proyecto
README.md	Descripcion y enlace al video YouTube

Reproducibilidad: SEED=42 fijado en todos los notebooks. Split determinista por lesion_id. Dataset descargable automaticamente desde Kaggle (Secrets) o Google Drive publico como fallback.

12. Conclusiones

1. Los pesos de clase son imprescindibles en datasets medicos desbalanceados. Sin ellos el recall de malignos es cero; con ellos sube a 0.49 (+49 puntos).

2. El transfer learning supera al entrenamiento desde cero: balanced accuracy de 0.745(ResNet50) vs 0.644 (baseline), con solo 5 epocas.
3. El fine-tuning progresivo es efectivo: el salto visible en las curvas al inicio de la Fase 2 confirma que descongelar layer4 mejoro el modelo multiclase llevandolo a balanced accuracy de 0.694 y AUC-ROC macro de 0.949.
4. El AUC-ROC es la metrica mas robusta para problemas medicos desbalanceados: el valor de 0.949 indica capacidad discriminativa sobresaliente.
5. El recall de melanoma (0.54) no alcanza el objetivo clinico (>85%), indicando que el modelo actual es adecuado como herramienta de apoyo pero no como sistema autonomo de diagnostico.

13. Referencias

- [1] Tschandl, P., Rosendahl, C., & Kittler, H. (2018). *The HAM10000 dataset*. *Scientific Data*, 5, 180161. doi:10.1038/sdata.2018.161
- [2] Esteva, A. et al. (2017). *Dermatologist-level classification of skin cancer with deep neural networks*. *Nature*, 542, 115-118. doi:10.1038/nature21056
- [3] He, K. et al. (2016). *Deep Residual Learning for Image Recognition*. *CVPR 2016*.
- [4] Simonyan, K. & Zisserman, A. (2014). *Very Deep Convolutional Networks*. *arXiv:1409.1556*.
- [5] Tan, M. & Le, Q. V. (2019). *EfficientNet*. *ICML 2019*. *arXiv:1905.11946*
- [6] Aggarwal, C. C. (2018). *Neural networks and deep learning*. Springer.
- [7] Goodfellow, I., Bengio, Y. & Courville, A. (2016). *Deep learning*. MIT Press.